

O corpus do projeto: *Construção de um corpus para busca de informações sobre portos*

Grupo - Enem

6 de outubro de 2026

Fatec Baixada Santista – Rubens Lara

Tecnologia em Ciência de Dados | Projeto Integrador III — Motor de Busca | Prof. Dr.
João Paulo Ferreira de Mello

Ana Luiza Bispo Aguiar – RA 00051352511020

Caio Kenji de Paula Maeshiro – RA 0051352511008

Lucas Murinelly Feliciano – RA 0051352511013

Pedro Santos Malaquias Rodrigues – RA 00513525110041

Repositório: PI3-ENEM

1 Introdução

A recuperação de informação visa facilitar a localização de conteúdos relevantes. Este projeto tem como foco os portos de Santos, Xangai e Roterdã, utilizando um motor de busca para recuperar informações sobre eles no corpus. O interesse pelo tema justifica-se pela importância dos portos no transporte e comércio. Por fim, serão apresentadas evidências para avaliar se o corpus responde adequadamente às necessidades de informação definidas.

2 A fonte e o documento

A fonte escolhida para a construção do corpus foi a Wikipédia em português. A escolha dessa fonte ocorreu devido à disponibilidade de informações textuais sobre os portos estudados e à possibilidade de realizar a coleta de forma programática por meio da API da Wikipédia (Wikimedia Foundation, 2026). As páginas utilizadas foram:

- *Porto de Santos* (Wikipédia, 2026b);
- *Porto de Xangai* (Wikipédia, 2026c);
- *Porto de Roterdão* (Wikipédia, 2026a).

O conteúdo utilizado é disponibilizado pela Wikipédia sob os termos da licença Creative Commons Atribuição-CompartilhaIgual (CC BY-SA), que permite a reutilização e adaptação do conteúdo desde que sejam respeitadas as condições estabelecidas pela licença.

As três páginas foram escolhidas por tratarem diretamente dos portos estudados e apresentarem informações relacionadas às necessidades de informação do projeto, como movimentação de cargas e contêineres, infraestrutura, história, desenvolvimento e importância econômica.

No corpus, cada parágrafo foi considerado um documento, pois essa unidade permite recuperar informações mais específicas do que uma página inteira. Assim, o motor de busca pode retornar um trecho relacionado à consulta, em vez de indicar somente uma página completa.

A escolha do tema está relacionada ao interesse em estudar e comparar os portos de Santos, Xangai e Roterdão. Como alternativa, poderiam ser utilizados portais institucionais das autoridades portuárias, mas optou-se pela Wikipédia por oferecer uma fonte comum aos três portos, facilitando a construção de um corpus mais uniforme.

3 Como o corpus foi obtido

O corpus foi obtido de três artigos da Wikipédia — Porto de Santos, Porto de Xangai e Porto de Roterdão — por meio da API da Wikipédia, em formato texto. Cada artigo foi dividido em parágrafos; parágrafos vazios foram removidos e adotou-se o critério de manter apenas parágrafos com 10 palavras ou mais. Esse limite evita trechos curtos com pouca informação relevante, sem reduzir excessivamente o corpus. Por fim, os parágrafos dos três artigos foram reunidos, e cada parágrafo passou a ser um documento.

4 Defesa do corpus

O corpus é adequado ao motor de busca por quatro razões: é coerente com o tema, pois seus 75 documentos vêm de páginas dedicadas aos portos de Santos, Xangai e Roterdão; usa o parágrafo como unidade, com média de 70,7 tokens, o que permite respostas específicas; é uniforme e reproduzível, por vir de uma única fonte coletada via API; e tem vocabulário suficiente (1946 termos distintos) para as consultas. Os problemas encontrados, como a baixa representação de Roterdão e o ruído do texto bruto, já têm tratamento previsto e não comprometem o corpus nesta fase.

A Tabela 1 reúne as verificações feitas sobre o corpus, e a Tabela 2 mostra de onde veio cada documento.

Tabela 1 – Diagnóstico do corpus

Verificação	Resultado
Tamanho (N documentos, páginas)	75 documentos de 3 páginas
Tokens por documento	10 a 237 (média 70,7)
Vocabulário bruto	1946 termos distintos em 5304 tokens
Página que domina	Porto de Xangai : 38 de 75 (51%)
Documentos suspeitos	9 com menos de 20 tokens; 0 com mais de 300
Sujeira	75 com acento, 75 com pontuação, 57 com dígitos (de 75)

Fonte: Elaborada pelos autores a partir de `docs.rds` e `origem.rds`.

Tabela 2 – Documentos por página de origem

Página	Documentos	Tokens (média)
Porto de Xangai	38	60,6
Porto de Santos	31	79,8
Porto de Roterdão	6	88,3

Fonte: Elaborada pelos autores.

Tamanho. São 75 documentos, o que está acima da meta estipulada. Diante disso, pretende-se arrumar o critério de corte, aumentando o limite mínimo de palavras por parágrafo e excluindo seções que não constituem prosa contínua, a fim de adequar o volume e manter a qualidade informacional do corpus para as próximas etapas. Tabela 2


Domínio de uma página. Nenhuma página responde por quase todo o corpus, mas a distribuição é desequilibrada. Observa-se que o Porto de Xangai responde por 51 por cento dos documentos, o que configura um desequilíbrio a corrigir. Como solução, pretende-se acrescentar novas páginas sobre o Porto de Roterdão para equilibrar a representação do corpus.

Documentos que não são prosa. Não se realizou uma inspeção individual dos documentos extremos. A única filtragem adotada foi a remoção de parágrafos vazios e a aplicação do critério de seleção de parágrafos com 10 palavras ou mais, o que não eliminou completamente trechos não prosaicos. Optou-se por manter esses casos nesta etapa e registrá-los, para tratá-los posteriormente.

Sujeira. Observa-se que a maioria dos documentos contém ruído típico de texto bruto: todos os 75 apresentam acentos e pontuação, e 57 contêm dígitos. Conclui-se que o corpus ainda se encontra em estado bruto, com elementos que deverão ser tratados na etapa de limpeza, sem prejuízo da análise atual.

A Figura 1 mostra a distribuição dos tamanhos.

Figura 1 – Tokens por documento



Fonte: Elaborada pelos autores.

Os termos mais frequentes são de, o, a, e, do, porto, da, em, para, um. Dos dez termos mais frequentes, apenas "porto" remete ao tema; os demais são artigos, preposições e conjunções. Isso indica que a frequência bruta é dominada por palavras gramaticais, o que sugere a necessidade de remover stopwords.

Veredito. Conclui-se que o corpus atende de forma adequada às consultas sobre os portos de Santos e Xangai, que reúnem 69 dos 75 documentos, mas de forma limitada às consultas sobre o Porto de Roterdão, representado por apenas 6. O descarte que de fato identificou um problema foi o domínio de uma página, e a correção prevista é o acréscimo de novas páginas, sem remoção de documentos.

O corpus é **provisório**: Espera-se que as próximas etapas alterem sua composição, com o acréscimo de páginas sobre Roterdão e a possível remoção dos trechos muito curtos após a limpeza.

Referências

Wikimedia Foundation. *API da Wikipédia em português (MediaWiki Action API)*. 2026. Disponível em: <<https://pt.wikipedia.org/w/api.php>>. Acesso em: 14 ago. 2026.

Wikipédia. *Porto de Roterdão*. 2026. Disponível em: <https://pt.wikipedia.org/wiki/Porto_de_Roterd%C3%A3o>. Acesso em: 14 ago. 2026.

Wikipédia. *Porto de Santos*. 2026. Disponível em: <https://pt.wikipedia.org/wiki/Porto_de_Santos>. Acesso em: 14 ago. 2026.

Wikipédia. *Porto de Xangai*. 2026. Disponível em: <https://pt.wikipedia.org/wiki/Porto_de_Xangai>. Acesso em: 14 ago. 2026.